# Contents



# 1 Machine Learning Grundlagen

**Disciplines in Machine Learning**

1. **Supervised Learning**
   - The algorithm is given labeled training data
   - The algorithm learns to predict the label of yet unseen examples
2. **Unsupervised Learning**
   - The algorithm is given unlabeled data
   - The algorithm detects and exploits the inherent structure of the data
3. **Semi-Supervised Learning**
   - A mixture of supervised and unsupervised machine learning techniques
   - Usually there is only very limited labeled data available
4. **Reinforcement Learning**
   - No data available but the algorithm is guided by a reward function
   - It searches the ideal behavior that maximizes the agent's reward

| | | |
|---|---|---|
| Identifying target groups for marketing campaigns using clustering techniques | passt zu | Unsupervised Machine Learning |
| Calculating product recommendations with collaborative filtering techniques | passt zu | Supervised Machine Learning |
| Market basket analysis using association rules | passt zu | Unsupervised Machine Learning |
| Medical image analysis for detection of skin diseases based on human expert markings | passt zu | Supervised Machine Learning |
| Search query analysis for e-commerce by semantical clustering | passt zu | Unsupervised Machine Learning |
| Prediction of selling prices for the real estate market | passt zu | Supervised Machine Learning |
| Dimensionality reduction for data visualization | passt zu | Unsupervised Machine Learning |
| Learning to play Jass by self-play | passt zu | Reinforcement Machine Learning |
| Detecting animals on high-resolution photographs | passt zu | Supervised Machine Learning |
| Identifying most-valuable customers on e-commerce platforms using transactions and tracking data | passt zu | Unsupervised Machine Learning |

# 2 Data Quality Assessment

1. Data Cleaning[1]
   (a) Dublizierte Daten erkennen und entfernen
   (b) Daten mit nullen können ersetzt werden.

[1] Auch wenn die Datenqualität selbständig verbessert werden kann sollten: alle Änderungen dokumentiert werden, data-repository mit versionierung verwendet werden, den Herausgeber der Daten auf fehler in den Daten hinweisen

(c) Daten Machine Learning freundlicher gestalten (z.B. für Farben eigene Zeilen erstellen, damit die Euklid-Distanz gerechnet werden kann.

2. Analyse mit Hilfe von

(a) 5 Nummer Zusammenfassung (median Q2, Quartile Q1 und Q3 sowie min und max)

(b) Boxplots um das Datenset auf Ausreisser zu prüfen.

(c) Varianz und Standardabweichung berechnen

# 3 Machine Learning Fundamentals

Euklid Distanz

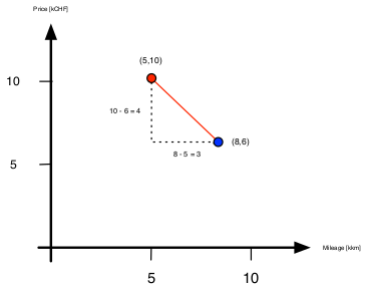


Kosinus Ähnlichkeit

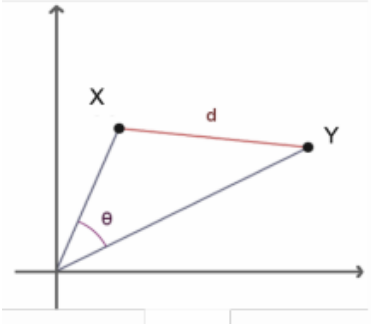


Formel Kosinus Similarity

$$sim(X,Y) = \frac{\langle X,Y\rangle}{||X||||Y||} = \frac{\sum_{i=1}^{n} x_i y_i}{\sqrt{\sum_{i=1}^{n} x_i^2}\sqrt{\sum_{i=1}^{n} y_i^2}}$$

$$dist(X,Y) = 1 - sim(X,Y)$$

# 4 Supervised Learning Basics

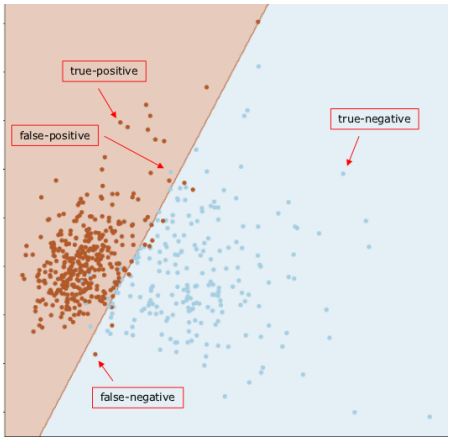


$$Accuracy = \frac{TP+TN}{Total}$$

$$Errorrate = \frac{FP+FN}{Total}$$

$$Sensitivity = \frac{TP}{ActualYes} = \frac{TP}{TP+FN}$$

$$Specificity = \frac{TN}{ActualNo} = \frac{TN}{TN+FP}$$

$$Precision = \frac{TP}{PredictedYes} = \frac{TP}{TP+FP}$$

# 5 Linear Regression

Das Modell hat generell die folgende Form: $y = h_\theta(x) = \theta_0 + \theta_1 x$.

Mit $\bar{x}$ und $\bar{y}$ als Mittelwerte der Datenreihe, können somit die Werte $\theta_1$ und $\theta_0$ berechnet werden. [2]

$$\theta_1 = \frac{\sum_{i=1}^{n}(y^{(i)} - \bar{y})(x^{(i)} - \bar{x})}{\sum_{i=1}^{n}(x^{(i)} - \bar{x})} = \frac{S_{xy}}{S_{xx}} \qquad \theta_0 = \bar{y} - \theta_1 \bar{x}$$

# 6 Gradient Descent

Mit der Kostenfunktion

$$J(\theta) = \frac{1}{2n}\sum_{i=1}^{n}(h(\theta, x^{(i)}) - y^{(i)})^2$$

wo $h(\theta, x^{(i)})$ die Vorhersage von $y$ ist und als

$$h(\theta_k, x^{(i)}) = (x^{(i)})^T\theta = \theta_0 + \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} + ... + \theta_m x_m^{(i)}$$

ausgeschrieben wird, kann $\theta$ optimiert werden. Diese wird mit $\theta = (X^T X)^{-1}X^T y$ umgesetzt. In python wird das mit X als $n \times m$ Matrix, bei der die erste Spalte mit Einsen aufgefüllt wurde und mit y als Zielwert $\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ ... \\ \theta_m \end{bmatrix}$ definiert wird.

```
theta = np.linalg.inv(X.T.dot(X)).dot(X.T).dot(y)
```

Korrelation liegt immer zwischen $-1 <= r <= 1$. $r = 0$ bedeutet keine Korrelation und $|r| = 1$ vollständige Korrelation.

# 7 Logistische Regression (eigentlich Klassifikation)

Logistische Regression zielt darauf ab eine binäre Zuordnung vorzunehmen (z.B. Brustkrebs oder nicht; Spam-Mail oder nicht etc.). Dabei können die unabhängigen Variablen numerisch (12mm) oder kategorisch (mag Skifahren) sein.

Die Logistische Funktion nennt sich auch "Siegmoid Funktion" und lautet wie folgt:

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{e^z + 1}, z \in \mathbb{R}$$

Die Logistische Funktion ist auch die neue Hypothese:

$$h_\theta(x) = \frac{1}{1 + e^{\theta^T x}}$$

Die Ableitungen der Logistischen Funktion sehen folgendermassen aus.

$$\sigma'(x) = \sigma(z)(1 - \sigma(z))$$

[2] Bei $var^{(i)}$ ist $i$ ein Index für den Datenpunkt und kein Exponent.

$$\sigma''(z) = \sigma(z)(1-\sigma(z))(1-2\sigma(z))$$

Wenn $z > 0$ wird die Aussage als wahr (Wahrscheinlichkeit über 0.5) und sonst als falsch interpretiert.

$z$ ist mit $z = \theta^T x = \theta_0 + \theta_1 x_1 + \theta_2 x_2$ gegeben.

Mit der Logistischen Regression muss auch eine neue Kostenfunktion gewählt werden, welche folgendermassen aussieht:

$$Cost(h_\theta(x), y) = \begin{cases} -log(h_\theta(x)) & wenn\ y = 1 \\ -log(1 - h_\theta(x)) & wenn\ y = 0 \end{cases}$$

Damit ergibt sich die Formel für Gradient Descent wie folgt:

$$\theta_{k+1} = \theta_k - \alpha \frac{1}{n} X^T(\sigma(X\theta_k) - y)$$

Codebeispiel zum trainieren von $\theta$

```
def sigmoid(z):
        return 1/(1+np.exp(-z))


def cost_function(X, y, theta):
        y_hat = sigmoid(np.dot(X, theta))
        J_i =-y*np.log(y_hat)-(1-y)*np.log(1-y_hat)
        J = J_i.sum()/len(y)
        return J


def update_theta(X,y, theta, alpha):
        theta -= alpha * np.dot(X.T,sigmoid(np.dot(X, theta))-y)/len(y)
        return theta


def train(X, y, theta, alpha, kmax):
        cost_history=[]
        for i in range(kmax):
                theta=update_theta(X,y,theta,alpha)
                cost = cost_function(X,y,theta)
                cost_history.append(cost)
```

```
    return theta, cost_history
```

Danach wird zuerst ein $\theta$ definiert, wo die vorgegebenen startwerte angegeben werden. Daraus trainiert der Algorythmus danach mit $\alpha$ als Schrittgrösse und **kmax** als Anzahl Zyklen die optimalen Werte für $\theta$